

課程期末專題

應用 Machine Learning 於公共物聯網

學生：王凱弘

學號：C112151111

E-mail : 

手機號碼 : 

中華民國 2024 年 8 月

目錄

壹、研究動機	1
1、減少損失	1
2、提升應急反應效率	1
3、促進公共安全	1
貳、研究目的	2
1、理解 AI、機器學習和深度學習的關係：	2
2、深入分析機器學習模型：	2
3、比較生成式模型與判別式模型：	2
4、實際應用案例分析	2
5、技術與應用的整合分析	3
參、研究過程或方法	3
1、AI、機器學習與深度學習的概述與關係：	3
2、機器學習分類概述	4
3、生成式模型 vs. 判別式模型	4
4、演算法介紹	4
5、研究過程	12
6、MLP（多層感知器）與隨機森林（Random Forest）範例	14
7、遭遇困難&解決困難	17
肆、研究結果	19
1、MLP（多層感知器）	19
2、隨機森林（Random Forest）	20
3、比較結果	20
伍、結論	21
陸、參考文獻資料	21

圖目錄

圖 1、AI、ML、DL 之差異	3
------------------------	---

壹、 研究動機

隨著科技的迅速發展，公共物聯網（IoT）在智慧城市、環境監測和災害預警系統中的應用日益增多。智慧城市利用 IoT 技術整合各種設備和數據源，以提高城市運營的效率和居民的生活品質。例如，智能交通系統可以優化交通流量，減少擁堵；環境監測系統可以實時跟蹤空氣質量和水質變化，保障公共健康；災害預警系統則利用 IoT 設備監控自然災害的預兆，及早發出警報，幫助降低災害損失。

本研究旨在探索 AI、ML 和 DL 技術在這些應用中的潛力，具體包括如何利用這些技術提高災害預測的準確性和公共資源的管理效率。研究的價值在於：

1、 減少損失

通過改進災害預測系統的準確性，可以及早發出警報，從而減少人員傷亡和財產損失。準確的預測能夠幫助政府和應急機構制定更加有效的應急計劃，提升災害管理的效率。

2、 提升應急反應效率

利用先進的 AI 和 ML 技術，可以優化應急資源的分配和調度，確保資源能夠迅速而有效地被調用到最需要的地方。這不僅提升了應急反應的速度，也提高了資源的使用效益。

3、 促進公共安全

強化環境監測和智慧城市系統中的數據分析能力，有助於及時發現和處理潛在的安全威脅，保障市民的生活安全。

通過深入研究 AI、ML 和 DL 技術在公共物聯網中的應用，本研究希望為實現更智能的公共安全和資源管理提供有價值的見解和實踐指導。

貳、 研究目的

本研究的目的是深入探討人工智慧 (AI)、機器學習 (ML) 和深度學習 (DL) 之間的關係，並探討它們在實際應用中的應用潛力。具體目的如下：

1、 理解 AI、機器學習和深度學習的關係：

- i. 探討 AI、機器學習和深度學習的基本概念和相互關係，分析它們在技術架構和應用領域中的不同角色和貢獻。
- ii. 理解深度學習如何作為機器學習的子領域，專注於處理複雜的數據模式和學習過程。

2、 深入分析機器學習模型：

- i. 研究監督式學習模型和非監督式學習模型的基本原理、應用場景和優缺點，並比較這兩種類型模型在不同問題上的表現。
- ii. 探討機器學習模型如何根據帶有標籤的資料進行訓練以進行預測或分類，以及如何使用無標籤資料來探索和形成資料群組。

3、 比較生成式模型與判別式模型：

- i. 比較生成式模型和判別式模型的基本概念和技術特點，並分析它們在資料生成和分類預測中的不同應用。
- ii. 探討生成式模型如何從現有數據中學習機率分布並產生新實例，以及判別式模型如何進行標籤分類和預測。

4、 實際應用案例分析

- i. 評估 AI、ML、DL 技術在公共物聯網中的應用，尤其是在災害預測和資源管理方面的潛力。
- ii. 通過實際案例，分析這些技術如何實現更準確的災害預測，提升公共資源的管理效率，並探討其在現實世界中的實施挑戰和機遇。

5、技術與應用的整合分析

- i. 研究如何將 AI、ML、DL 技術有效地整合到公共物聯網系統中，促進災害預測和資源管理的實際應用。

參、評估不同技術在系統中的角色和影響，提出改進建議和未來研究方向。

參、研究過程或方法

1、AI、機器學習與深度學習的概述與關係：

- i. 人工智慧 (AI)：廣義上指能夠執行需要人類智能的任務的技術。它包括各種範疇，如規則基系統、專家系統、機器學習和深度學習。AI 的目標是創建能夠模擬或超越人類智能的系統。

- ii. 機器學習 (ML)：AI 的子領域，專注於開發能夠自動從數據中學習並做出預測或決策的算法。與傳統的編程不同，機器學習模型依賴於數據訓練，以提高其表現。

- iii. 深度學習 (DL)：機器學習的子領域，利用多層神經網絡處理和分析大量數據，特別適合處理高維度和非結構化數據，如圖像、語音和文本。深度學習的出現推動了許多 AI 應用的發展，如圖像識別、自然語言處理和自動駕駛。




圖 1、AI、ML、DL 之差異

2、機器學習分類概述

i. 監督式學習：在監督式學習中，我們使用帶標籤的數據來訓練模型。模型學習輸入數據與標籤之間的映射關係，並用來預測新的輸入數據的標籤。監督式學習主要分為分類和迴歸兩類，其中分類任務的目標是將數據分配到預定的類別中。

ii. 非監督式學習：與監督式學習不同，非監督式學習不使用標籤數據。模型從數據中學習結構和模式，如聚類和降維。

3、生成式模型 vs. 判別式模型

i. 生成式模型：生成式模型學習數據的聯合分佈，能生成與訓練數據相似的新樣本。常見的生成式模型有高斯混合模型（GMM）、朴素貝葉斯（Naive Bayes）、生成對抗網絡（GAN）和變分自編碼器（VAE）。

ii. 判別式模型：判別式模型學習數據和標籤之間的條件分佈，專注於分類任務。常見的判別式模型有邏輯迴歸（Logistic Regression）、支持向量機（SVM）、神經網絡（如 MLP, CNN）、隨機森林（Random Forest）和 K-近鄰算法（K-NN）。

4、演算法介紹

i. 生成式模型

a. 高斯混合模型（GMM, Gaussian Mixture Model）

演算方式：

I. 模型構建：

GMM 假設數據由多個高斯分布組成，每個分布稱為一個“組件”。

每個組件有自己的均值、協方差矩陣和混合權重。

II. 期望最大化 (EM) 算法：

E 步驟：根據當前的參數估算每個數據點屬於每個組件的概率。

M 步驟：最大化期望值，更新每個組件的均值、協方差和混合權重。

III. 收斂：

重複 E 步驟和 M 步驟，直到模型參數收斂。

公共物聯網應用場景：異常檢測與預警系統、資源管理與優化和人員流動和行為分析。

b. 朴素貝葉斯 (Naive Bayes)

演算方式：

I. 模型假設：

假設特徵之間是條件獨立的，即給定類別的情況下，特徵彼此獨立。

II. 概率計算：

使用貝葉斯定理計算每個類別的後驗概率：

$$P(C|X)=\frac{P(X|C) \cdot P(C)}{P(X)} \quad P(C|X)=P(X)P(X|C) \cdot P(C)$$

其中 $P(X|C)$ 是給定類別 C 下特徵 X 的條件概率， $P(C)$ 是類別的先驗概率。

III. 預測：

選擇具有最高後驗概率的類別作為預測結果。

公共物聯網應用場景：異常檢測與安全防護、預測與需求分析和智能交通管理。

c. 生成對抗網絡 (GAN, Generative Adversarial Network)

演算方式：

I. 模型結構：

包括生成器 (Generator) 和判別器 (Discriminator)

兩個神經網絡。

生成器：生成類似真實數據的假數據。

判別器：區分真實數據和生成器生成的假數據。

II. 對抗訓練：

生成器：試圖生成能夠騙過判別器的假數據。

判別器：試圖正確區分真實數據和假數據。

兩者通過對抗訓練達到均衡，生成器的目標是最小化判別器的識別能力。

III. 模型更新：

使用梯度下降法更新生成器和判別器的參數。

公共物聯網應用場景：數據增強與合成、模擬與預測和智能設備生成。

d. 變分自編碼器 (VAE, Variational Autoencoder)

演算方式：

I. 模型結構：

包括編碼器 (Encoder) 和解碼器 (Decoder) 兩部分。

編碼器：將輸入數據映射到潛在空間的概率分佈。

解碼器：從潛在空間的樣本中生成數據。

II. 變分推斷：

使用變分推斷方法估計潛在變量的分佈。

損失函數：由重構損失（衡量重構數據與原數據的差異）和 KL 散度（衡量潛在變量的分佈與先驗分佈的差異）組成。

III. 模型更新：

使用變分推斷方法進行模型訓練。

公共物聯網應用場景：數據生成與增強、特徵學習與降維和生成數據的數據隱私保護。

ii. 判別式模型

a. 邏輯迴歸（Logistic Regression）

演算方式：

I. 模型構建：

使用線性組合來預測類別概率：

$$P(Y=1|X)=\sigma(W \cdot X+b) \quad P(Y=1 | X) = \sigma(W \cdot X + b)$$

其中 σ 是 Sigmoid 函數，將輸出轉換為 0 到 1 之間的概率。

II. 損失函數：

使用交叉熵損失函數來度量預測概率與實際標籤之間的差異。

III. 參數優化：

通過梯度下降法更新模型參數，以最小化損失函數。

應用場景：二分類問題，如疾病預測和客戶流失預測。

b. 支持向量機 (SVM, Support Vector Machine)

演算方式：

I. 模型構建：

尋找一條超平面（或多維超平面），使得類別之間的邊界最大化。

線性 SVM：在原始特徵空間中找到分隔超平面。

非線性 SVM：通過核函數將數據映射到更高維的特徵空間，找到超平面。

II. 損失函數：

使用最大邊界損失函數（如合頁損失）來度量分類錯誤。

III. 參數優化：

通過二次規劃問題來最小化損失函數和正則化項。

公共物聯網應用場景：異常檢測、故障診斷和資源管理。

c. 多層感知器 (MLP, Multi-Layer Perceptron)

演算方式：

I. 網絡架構：

輸入層：接收原始數據特徵，每個神經元對應一個特徵。

隱藏層：一或多層，每層由多個神經元組成，每個神經元通過激勵函數處理輸入。

輸出層：產生最終的預測結果，對於分類問題，輸出層神經元的數量等於類別數。

II. 前向傳播：

每個神經元接收來自前一層的輸入，通過加權和加上偏置進行計算。

計算公式： $z = W \cdot x + bz = W \cdot x + b$

使用激勵函數進行非線性變換，常用的激勵函數包括 ReLU (Rectified Linear Unit)、Sigmoid、Tanh 等。

III. 損失計算：

通過損失函數計算模型的預測結果與真實標籤之間的誤差。常用的損失函數包括交叉熵損失 (Cross-Entropy Loss) 和均方誤差損失 (Mean Squared Error Loss)。

IV. 反向傳播：

使用梯度下降法或其變體 (如 Adam、RMSprop) 來最小化損失函數，通過計算損失對每個參數的梯度，調整權重和偏置。

V. 權重更新：

根據計算出的梯度更新權重和偏置，以改進模型性能。

公共物聯網應用場景：MLP 常用於預測和分析、異常檢測和其他需要非線性建模的問題。

d. CNN (卷積神經網絡):

演算方式：

卷積層：使用卷積核提取圖像的特徵。

池化層：通過下採樣操作減少特徵維度，降低計算複雜度。

全連接層：將卷積層和池化層提取的特徵用於分類或回歸。

公共物聯網應用場景：視頻監控和安全、環境監測和智能家居。

e. 隨機森林 (Random Forest)

演算方式：

I. 數據隨機化：

樣本隨機抽樣：從原始數據集中隨機抽取樣本來構建每棵決策樹，這一過程稱為自助抽樣法 (Bootstrap Sampling)。

特徵隨機選擇：在每次分裂節點時，隨機選擇特徵子集，以決定最佳分裂。這有助於提高模型的泛化能力。

II. 決策樹構建：

每棵決策樹獨立構建，通過不斷地選擇最佳分裂特徵來分割數據集。分裂的準則通常是基於信息增益、基尼不純度等。

樹的成長通常是基於預設的深度限制或最小樣本數，以防過擬合。

III. 預測：

每棵樹對新的數據點進行預測，並將預測結果進行投票或平均。

分類：每棵樹投票決定最終的類別，最終預測結果是所有樹投票結果的加權和或簡單投票。

回歸：對於回歸問題，最終預測是所有樹預測結果的平均。

IV. 模型評估：

通過交叉驗證或在測試集上評估隨機森林模型的性能，常用的指標包括準確率、精確度、召回率和 F1 分數。

公共物聯網應用場景：智能監控與安全、環境監測、智能家居等。

f. K-近鄰算法 (K-NN, K-Nearest Neighbors)

演算方式：

I. 模型構建：

無需顯式訓練，保存所有訓練數據。

II. 預測：

對於新樣本，找到距離其最近的 K 個鄰居。

通過鄰居的標籤進行投票或加權平均，確定預測結果。

公共物聯網應用場景：智能家居和健康監測。

g. K-means

演算方式：

I. 模型構建：

隨機初始化 K 個簇中心。

II. 聚類過程：

分配步驟：將每個數據點分配給距離最近的簇中心。

更新步驟：計算每個簇內數據點的均值，更新簇中心。

III. 收斂：

重複分配步驟和更新步驟，直到簇中心不再改變。

公共物聯網應用場景：智能家居、健康監測和智能交通。

5、研究過程

i. 在公共物聯網找尋資料：

確定研究的具體問題和目標。從公共物聯網系統中收集相關的數據，這些數據可能來自各種感測器、設備、或公共數據庫。

ii. 研究演算法：

研究和選擇適合的機器學習或深度學習演算法。這可能包括分類演算法（如朴素貝葉斯、支持向量機）、回歸演算法、聚類演算法（如 K-means），或其他複雜的模型（如生成對抗網絡、變分自編碼器）。

iii. 選擇演算法模型：

根據你的數據特性和研究目標選擇最適合的演算法模型。這一步涉及理解每種模型的優缺點和適用場景。

iv.載入資料：

將從公共物聯網獲取的原始數據載入到我的分析環境 colab 中

v.分割資料：

將數據集分為訓練集和測試集，通常還可以有驗證集。這樣可以用於訓練模型、調整模型參數和評估模型性能。

vi.標準化資料：

根據需要對數據進行預處理，如標準化或正則化，以確保數據在模型中表現良好。

vii.建構模型：

根據選擇的演算法構建模型。這可能包括設定模型參數和構建模型結構。

viii.訓練模型：

使用訓練集數據來訓練模型。這一過程涉及模型的學習和調整，以最佳化其性能。

ix.評估模型：

使用測試集或驗證集來評估模型的性能。這包括計算精度、召回率、F1 分數等指標，並確保模型的效果符合預期。

x.預測模型：

使用訓練好的模型進行實際的預測。這一步涉及將模型應用於新的或未見過的數據上，並根據預測結果進行分析。

6、MLP（多層感知器）與隨機森林（Random Forest）範例

i. MLP（多層感知器）

使用方式：MLP 是一種前向神經網絡，包含多層隱藏層，每層由多個神經元組成。選擇使用 MLP 作為範例，是因為它能夠有效處理高維度和非線性數據，適用於需要識別數據中的複雜模式的任務，如圖像識別和語音處理。MLP 模型通過前向傳播和反向傳播來學習數據中的複雜模式。主要步驟包括：

a. 研究背景與數據準備

在這個範例中，我們的目標是使用多層感知器（MLP）來預測災情類別。數據來自公共物聯網系統中的一個 Excel 文件，包含了不同地區的災情資訊。

b. 數據載入與預處理

數據載入：首先，從 GitHub 上載入 Excel 文件，並選擇需要的工作表。

處理缺失值：刪除目標變數（災情類別）中有缺失值的行，以保證模型訓練的質量。

標籤編碼：將災情類別進行標籤編碼，轉換為數字形式，便於後續處理和模型訓練。

填充缺失值：對其他特徵中的缺失值進行填充，這裡使用 '缺失值' 進行填充，以避免因缺失值影響模型性能。

c. 數據分割與過濾

分層抽樣：將數據隨機分為訓練集和測試集，確保每個類別在兩個數據集中的比例一致。

過濾樣本：基於樣本數量的閾值過濾掉樣本數量少於特定數量的類別，以平衡數據集。

d. 特徵工程

One-Hot 編碼：將分類特徵（如縣市、災情細項、災情描述）轉換為數值型特徵，以便於模型處理。

標準化：對數據進行標準化處理，將每個特徵縮放到相同的尺度，有助於提升模型的性能。

e. 模型構建與訓練

建立 MLP 模型：設置多層感知器的隱藏層大小（如 100 個神經元）和最大迭代次數（如 100 次），並訓練模型。

模型訓練：使用訓練集數據來訓練 MLP 模型，使其能夠學習如何根據輸入特徵預測災情類別。

f. 模型評估與預測

進行預測：在測試數據上使用訓練好的 MLP 模型進行預測，獲取模型的預測結果。

評估模型：計算模型的準確率和分類報告，以評估模型的性能。準確率反映了模型預測正確的比例，而分類報告提供了詳細的性能指標，如精確度、召回率和 F1 分數等。

ii. 隨機森林 (Random Forest)

使用方式：隨機森林是一種集成學習方法，通過構建多棵決策樹進行分類或回歸。選擇使用隨機森林作為範例，因為它在處理具有高維度特徵和噪聲的數據集時表現出色，並且具有良好的穩健性和抗過擬合能力。這使得隨機森林非常適合用於需要高準確性和穩健性的分類任務。其主要步驟包括：

a. 研究背景與數據準備

在這個範例中，我們使用隨機森林模型來預測災情類別。數據來自公共物聯網系統中的一個 Excel 文件，包含了不同地區的災情資訊。

b. 數據載入與預處理

數據載入：首先，從 GitHub 上載入 Excel 文件，並選擇需要的工作表。

處理缺失值：刪除目標變數（災情類別）中有缺失值的行，以保證數據質量。

標籤編碼：將災情類別轉換為數字編碼，這有助於模型理解和處理目標變數。

填充缺失值：對其他特徵中的缺失值進行填充，使用 '缺失值' 進行填充，以確保數據完整。

c. 數據分割與過濾

分層抽樣：將數據隨機分為訓練集和測試集，確保每個類別在兩個數據集中的比例一致。

過濾樣本：根據樣本數量的閾值過濾掉樣本數量少於特定數量的類別，以減少數據偏倚，保證模型的可靠性。

d. 特徵工程

One-Hot 編碼：將分類特徵（如縣市、災情細項、災情描述）轉換為數值型特徵，這樣模型才能夠有效處理這些特徵。

標準化：對特徵數據進行標準化處理，使每個特徵的數值範圍相近，這有助於提升模型性能。

e. 模型構建與訓練

建立隨機森林模型：設置隨機森林的樹木數量（如 100 顆樹），並指定隨機種子，以便重現實驗結果。

模型訓練：使用訓練集數據來訓練隨機森林模型。隨機森林通過建立多個決策樹並對結果進行投票來進行預測，這種集成方法有助於提高模型的穩定性和準確性。

f. 模型評估與預測

進行預測：在測試數據上使用訓練好的隨機森林模型進行預測，得到每個樣本的預測災情類別。

評估模型：計算模型的準確率，這表示模型預測正確的比例。同時生成分類報告，提供精確度、召回率和 F1 分數等詳細性能指標，幫助理解模型在各類別上的表現。

7、 遭遇困難&解決困難

i. 總資料過多，訓練過久

在載入資料後，所有資料高達 3 萬多筆，訓練時需耗費大量時間，所以採取隨機抽樣 5000 筆資料，發現資料過少，改為抽樣 1 萬筆資料，但為確保每個類別的比例與原數據集相同，所以改為分層抽樣。

ii. 某些標籤的資料過少，訓練不完整

在載入資料後，某些標籤的資料過少，過少資料的標籤訓練就會過少，會導致模型對少數類別的預測性能下降，就會導致預測結果不穩定或不準確，我一開始使用 SMOTE 將過少資料的標籤生成更多相似資料，但是因為資料太少無法生成相似資料，所以我將資料限制數量，只要資料量少於 100 筆的標籤一律刪除。

肆、 研究結果

1、 MLP（多層感知器）

i. 準確率: 0.9267

ii. 分類報告:

類別	精確度	召回率	F1 分數	支持度
其他災情	0.84	0.99	0.91	1822
土石災情	1.00	0.99	0.99	224
廣告招牌災情	0.98	0.98	0.98	337
建物毀損	0.75	0.06	0.10	54
橋梁災情	0.50	0.03	0.05	35
民生、基礎設施災情	1.00	0.99	0.99	640
水利設施災情	0.70	0.16	0.26	44
積淹水災情	0.99	1.00	1.00	743
路樹災情	1.00	1.00	1.00	898
道路、隧道災情	0.87	0.06	0.11	221
準確率			0.93	5018
宏平均	0.86	0.62	0.64	5018
加權平均	0.92	0.93	0.90	5018

2、隨機森林（Random Forest）

i. 準確率: 0.9326

ii. 分類報告:

類別	精確度	召回率	F1 分數	支持度
其他災情	0.84	1.00	0.92	1822
土石災情	1.00	1.00	1.00	224
廣告招牌災情	1.00	1.00	1.00	337
建物毀損	1.00	0.04	0.07	54
橋梁災情	1.00	0.03	0.06	35
民生、基礎設施災情	1.00	1.00	1.00	640
水利設施災情	0.86	0.14	0.24	44
積淹水災情	1.00	1.00	1.00	743
路樹災情	1.00	1.00	1.00	898
道路、隧道災情	1.00	0.04	0.08	221
準確率			0.93	5018
宏平均	0.97	0.62	0.64	5018
加權平均	0.94	0.93	0.91	5018

3、比較結果

在這次研究中，隨機森林模型稍微超過了 MLP 模型，取得了更高的準確率（0.9326 vs. 0.9267）。隨機森林在各個類別上表現出更高的精確度和一致性，尤其在一些小類別上，如「建物毀損」和「橋梁災情」的表現上有所提升。未來可以進一步探索模型調優和其他算法，以提升分類性能。

伍、 結論

本研究探討了機器學習技術在公共物聯網中的應用，特別是針對災難歷史資料的分析與預測。雖然我們介紹了生成式模型與判別式模型的特性，但本研究的重點放在判別式模型的實際應用上，特別是多層感知器（MLP）和隨機森林模型。研究結果顯示，這些判別式模型在災難資料的分類與預測任務中展現了優異的性能，具有較高的準確性和穩定性。

將這些機器學習模型應用於公共物聯網的災難預警系統，不僅能有效提升災難應對的效率，還能通過準確的資料分析和預測技術，減少災難可能帶來的損害。未來的研究可進一步探討如何優化這些模型，或整合其他相關技術，以進一步提升公共物聯網在災難管理中的智能化水平。

陸、 參考文獻資料

- Alpaydin, E. (2020). *Introduction to Machine Learning* (4th ed.). MIT Press.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press.
- Ng, A. (2018). *Machine Learning Yearning: Technical Strategy for AI Engineers, In the Era of Deep Learning*. deeplearning.ai.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Silver, D. (2015). *Mastering the Game of Go with Deep Neural Networks and Tree Search*. Nature, 529(7587), 484-489.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). *Deep Learning*. Nature, 521(7553), 436-444.
- Kingma, D. P., & Welling, M. (2014). *Auto-Encoding Variational Bayes*. arXiv preprint arXiv:1312.6114.

- Radford, A., Metz, L., & Chintala, S. (2016). *Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks*. arXiv preprint arXiv:1511.06434.
- Schmidhuber, J. (2015). *Deep Learning in Neural Networks: An Overview*. Neural Networks, 61, 85-117.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- Vapnik, V. N. (1998). *Statistical Learning Theory*. Wiley.
- Zhang, J., Zhao, Y., & Chen, Y. (2020). *Intelligent Disaster Management System Based on Machine Learning and IoT*. IEEE Access, 8, 56734-56747.
- Liu, J. (2020, December 8). 機器學習與深度學習之差異. HackMD.
https://hackmd.io/@JimmyLiu0530/Hk6pW_3oD
- 民生公共物聯網. (n.d.). 民生公共物聯網 <https://history.colife.org.tw/#/>